

모델 성능 측정 메트릭

분류 · 회귀 · Confusion Matrix · Precision/Recall

성능 지표를 왜 나눠서 봐야 하는가

모델 평가는 문제의 종류와 오류 비용에 따라 달라진다

같은 정확도라도 현장에서의 의미는 완전히 다를 수 있습니다.



분류 문제에서는 “맞췄는가”만이 아니라 “어떤 종류의 실수를 했는가”가 중요합니다.

회귀 문제에서는 예측값이 실제값에서 얼마나 벗어났는지를 크기와 해석 방식에 따라 나눠 봅니다.

분류 성능의 기본: Confusion Matrix

정답과 예측을 Positive / Negative 기준으로 나누어 보는 표

		예측	
		Positive	Negative
실제	Positive	TP	FN
	Negative	FP	TN

네 칸의 의미

TP: 실제 Positive를 Positive로 예측

FP: 실제 Negative를 Positive로 오탐

FN: 실제 Positive를 Negative로 놓침

TN: 실제 Negative를 Negative로 예측

Accuracy = $(TP + TN) / \text{전체}$

Precision = $TP / (TP + FP)$

Recall = $TP / (TP + FN)$

F1 Score = $2 \times P \times R / (P + R)$

암 분류 예시: Recall이 중요한 상황

Positive = 암 환자, FN = 암 환자를 정상으로 놓친 경우

암 진단 보조 모델에서는 놓친 환자(FN)의 비용이 매우 큽니다.

예측		
	암	정상
암	TP 90	FN 10
정상	FP 45	TN 855

Accuracy
94.5%

Precision
66.7%

Recall
90.0%

F1
76.6%

Recall = $90 / (90 + 10) = 90.0\%$
실제 암 환자 100명 중 90명을 찾아냄

Precision = $90 / (90 + 45) = 66.7\%$
암으로 예측한 135명 중 실제 암 환자는 90명

핵심: 암 분류에서는 “정확히 맞힌 비율”보다 “실제 암 환자를 얼마나 놓치지 않았는가”가 더 중요한 기준이 될 수 있습니다.

스팸 필터 예시: Precision이 중요한 상황

Positive = 스팸 메일, FP = 정상 메일을 스팸함으로 보낸 경우

스팸 필터에서는 정상 메일을 차단하는 실수(FP)가 치명적일 수 있습니다.

예측		
	스팸	정상
스팸	TP 240	FN 60
정상	FP 10	TN 690

Accuracy

93.0%

Precision

96.0%

Recall

80.0%

F1

87.3%

Precision = $240 / (240 + 10) = 96.0\%$
스팸함으로 보낸 메일 대부분이 실제 스팸

Recall = $240 / (240 + 60) = 80.0\%$
일부 스팸은 받은 편지함에 남을 수 있음

핵심: 스팸 필터에서는 “스팸을 최대한 많이 잡기”보다 “정상 메일을 잘못 차단하지 않기”가 더 중요할 수 있습니다.

Precision과 Recall의 균형

분류 임계값을 조정하면 두 지표가 서로 영향을 준다

모델의 점수를 어디서 Positive로 자를 것인지가 운영 전략이 됩니다.

낮은 임계값

Positive로 많이 분류
Recall 상승
FP 증가 가능



높은 임계값

확실한 것만 Positive
Precision 상승
FN 증가 가능


$$F1 \text{ Score} = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$$

Precision과 Recall을 하나의 값으로 요약할 때 사용
단, FP와 FN의 비용이 다르면 F1만으로 판단하면 안 됨

ROC Curve와 Precision-Recall Curve

임계값 변화에 따른 분류 모델의 전체 성능을 곡선으로 확인

ROC Curve




x축: $FPR = FP / (FP + TN)$

y축: $TPR = Recall$

AUC가 클수록 전반적 구분 성능이 좋음

Precision-Recall Curve



x축: Recall

y축: Precision

불균형 데이터에서 Positive 탐지 성능을 보기 좋음

Positive가 적은 문제에서는 ROC만으로 모델이 좋아 보일 수 있으므로 PR Curve를 함께 확인합니다.

회귀 성능 지표: MSE, MAE, R²

예측값이 실제값에서 얼마나 벗어났는지를 측정

회귀는 맞고 틀림보다 “얼마나 멀리 틀렸는가”를 봅니다.

MSE
Mean Squared Error
오차 제곱의 평균
큰 오차에 더 민감

MAE
Mean Absolute Error
절대 오차의 평균
실제 단위로 해석 쉬움

R²
결정계수
모델이 변동을 설명하는 비율
1에 가까울수록 좋음

$$\text{MSE} = \text{mean}((y - \hat{y})^2)$$

$$\text{MAE} = \text{mean}(|y - \hat{y}|)$$

$$R^2 = 1 - \text{SSE} / \text{SST}$$

지표 선택의 원칙

모델 성능은 숫자 하나가 아니라 운영 목적에 맞춰 해석해야 한다

좋은 지표는 “수학적으로 좋아 보이는 값”이 아니라 “현장의 의사결정에 맞는 값”입니다.

암 분류
놓치면 위험
Recall 우선

스팸 필터
정상 메일 차단 위험
Precision 우선

수요·가격 예측
오차 크기 해석
MAE / MSE / R^2

분류: Accuracy만 보지 말고 FP와 FN의 비용을 확인

불균형 분류: ROC-AUC와 PR Curve를 함께 확인

회귀: 오차의 크기, 단위, 이상치 민감도를 함께 해석

모델 평가는 “가장 높은 점수”를 찾는 과정이 아니라, 실제 문제에서 어떤 실수를 줄여야 하는지 정하는 과정입니다.